



**Кафедра информационных систем
в химической технологии**

**Институт тонких химических технологий
им. М.В. Ломоносова
РТУ МИРЭА**



ИНФОРМАЦИОННЫЕ СИСТЕМЫ В ХТ

Лекция 31. Управление данными

Содержание лекции

В данной лекции будут рассмотрены следующие темы:

-  Базы данных
-  SQL и NoSQL - особенности и сферы применения
-  Хранилища данных и инструменты ETL
-  Поточковая обработка данных
-  Технологии BigData и машинного обучения
-  Управление контентом

Примеры SQL БД

СУБД	Лицензия	Производительность	Масштабируемость	Поддержка JSON	Где используется
PostgreSQL	Открытая	Высокая	Отличная	Да	Веб, GIS, аналитика, enterprise
MySQL	Открытая	Высокая (OLTP)	Хорошая	Да (с MySQL 8)	Веб-приложения
SQLite	Открытая	Низкая (локальная)	Нет	Да	Мобильные/десктоп приложения
MS SQL	Проприетарная	Высокая	Хорошая	Да	Корпоративные решения (Windows)
Oracle	Проприетарная	Очень высокая	Отличная	Да	Финансы, крупный бизнес, госсектор
IBM Db2	Проприетарная	Очень высокая	Отличная	Да	Банки, телеком, большие предприятия

Примеры NoSQL БД

Тип NoSQL	Примеры	Оптимальные сценарии	Плюсы	Минусы
Документные	MongoDB, CouchDB	Веб-приложения, каталоги	Гибкость, JSON	Нет JOIN
Ключ-значение	Redis, DynamoDB	Кэш, сессии, очереди	Скорость, простота	Ограниченные запросы
Колоночные	Cassandra, Scylla	IoT, логи, big data	Масштабируемость	Нет сложных запросов
Графовые	Neo4j, ArangoDB	Соцсети, рекомендации	Оптимизация под связи	Сложность масштабирования
Поисковые	Elasticsearch	Full-text search, логи	Быстрый поиск, агрегации	Не ACID

ETL инструменты

 ETL (Extract, Transform, Load) — процесс извлечения, преобразования и загрузки данных

Инструмент	Тип	Плюсы	Минусы	Сценарии использования
Informatica	Enterprise	Мощность, коннекторы	Дорого, сложно	Финансы, ERP
Talend	Open-source	Гибкость, Big Data	Медленный на больших данных	Стартапы, интеграция
AWS Glue	Cloud	Managed, интеграция с AWS	Vendor lock-in	Облачные DWH
Apache NiFi	Streaming	Реалтайм, визуальный интерфейс	Требует кластера	IoT, потоковая обработка
dbt	ELT	SQL-трансформации, тестирование	Нет Extract/Load	Аналитика, облачные DWH

Хранилища данных

📡 Хранилище данных — это централизованное хранилище структурированных данных, оптимизированное для аналитики и отчетности. В отличие от операционных баз данных (OLTP), DWH предназначен для обработки больших объемов исторических данных и сложных запросов

📡 Основные характеристики

- 📡 ✓ Интеграция данных – объединяет данные из разных источников (БД, CRM, ERP, логов)
- 📡 ✓ Оптимизация под аналитику – поддерживает агрегации, оконные функции, OLAP-кубы
- 📡 ✓ Историчность – хранит данные за длительный период (месяцы/годы)
- 📡 ✓ Структурированная модель – звезда, снежинка (витрины данных)

Озера данных

- 🌐 Data Lake — это централизованное хранилище, позволяющее хранить сырые данные любого формата (структурированные, полуструктурированные, неструктурированные) в нативной форме без строгой схемы.
- 🌐 Основные характеристики
 - 🕒 Хранение любых данных – таблицы (CSV, Parquet), JSON, логи, изображения, аудио, видео
 - 🕒 Гибкость – схема определяется при чтении (Schema-on-Read), а не при записи
 - 🕒 Масштабируемость – работает с петабайтами данных (HDFS, S3, ADLS)
 - 🕒 Поддержка разных обработчиков – SQL, Spark, ML, потоковая аналитика

Итоги

В данной лекции были рассмотрены следующие темы:

-  Базы данных
-  SQL и NoSQL - особенности и сферы применения
-  Хранилища данных и инструменты ETL
-  Поточковая обработка данных
-  Технологии BigData и машинного обучения
-  Управление контентом